Nghiên cứu các yếu tố ảnh hưởng đến quyết định nghỉ việc của nhân viên: Tiếp cận bằng mô hình Hồi quy Logistic

Analyzing Factors Affecting Employee Attrition: A Logistic Regression Approach

Tác giả:

Nguyễn Thị Quỳnh Mai

Ngày 28 tháng 3 năm 2026

Mục lục

Danh sách hình **iii**

Danh sách bảng **iv**

Tóm tắt (Abstract) **1**

1 Giới thiệu **2**

1.1 Bối cảnh và bài toán 2

1.2 Mục tiêu 2

1.3 Đóng góp (Deliverables) 2

2 Dữ liệu **3**

2.1 Nguồn dữ liệu 3

2.2 Đặc tả biến (Feature specification) 3

2.3 Tổng quan bộ dữ liệu 4

2.4 Thống kê mô tả sơ bộ 4

2.5 Lưu ý về mất cân bằng lớp 5

3 Phương pháp (Methodology) **6**

3.1 Logistic Regression 6

3.1.1 Mô hình dự đoán xác suất (Bài toán và Công thức) 6

3.1.2 Lựa chọn hàm liên kết logit và cơ sở mô hình 7

3.1.3 Lý do lựa chọn Logistic Regression cho bài toán dự đoán nhân sự ... 7

3.1.4 Hàm mục tiêu và regularization 8

3.1.5 Phân biệt hai vai trò: sklearn Logistic Regression và statsmodels Logit 8

3.2 Tiền xử lý (Preprocessing) 8

3.3 Thiết kế thí nghiệm 9

3.4 Luồng xử lý tổng quát 9

4 Phân tích khám phá (EDA) **11**

4.1 Tỷ lệ nghỉ việc theo nhóm 11

4.2 Phân phối biến số theo quyết định nghỉ việc 12

5 Mô hình và đánh giá **14**

5.1 Thiết lập mô hình 14
5.2 Kết quả đánh giá (Metrics) 14
5.3 Biểu đồ đánh giá 15
5.4 Diễn giải chi tiết về trade-off 16

6 Suy luận thống kê: Odds Ratio (OR) 18
6.1 Từ hệ số β đến Odds Ratio 18
6.2 Kiểm định giả thuyết cho từng hệ số 18
6.3 Baseline (nhóm tham chiếu) cho biến phân loại 19
6.4 Bảng OR và Forest plot 19
6.5 Một số điểm diễn giải trọng tâm 21
6.6 Phương trình logit ước lượng 22

7 Thảo luận và hạn chế 23
7.1 Về ý nghĩa thực tiễn của OR với biến liên tục 23
7.2 Ngưỡng quyết định (Decision threshold) và trade-off 23
7.3 Giả định và các hướng kiểm định bổ sung 23
7.4 Ý nghĩa của intercept (hệ số chặn) 24
7.5 Thảo luận mở rộng và tổng kết hạn chế 24

8 Kết luận và khuyến nghị 25
8.1 Kết luận 25
8.2 Khuyến nghị (Actionable recommendations) 25
8.3 Tái lập (Reproducibility) 25

A Phụ lục: Bảng kết quả chi tiết 27
A.1 Kết quả đánh giá mô hình (metrics) 27
A.2 Bảng Odds Ratio đầy đủ 27

Danh sách hình vẽ

3.1 Sơ đồ luồng xử lý từ dữ liệu thô đến báo cáo kết quả 10

4.1 Tỷ lệ nghỉ việc theo OverTime 11
4.2 Tỷ lệ nghỉ việc theo JobRole 12
4.3 Phân phối Age theo trạng thái nghỉ việc 12
4.4 Phân phối MonthlyIncome theo trạng thái nghỉ việc 13
4.5 Phân phối YearsAtCompany theo trạng thái nghỉ việc 13

5.1 ROC curve 15
5.2 Confusion matrix 16

6.1 Forest plot Odds Ratio 21

Danh sách bảng

5.1 Kết quả đánh giá mô hình trên tập test 14
5.2 Confusion matrix 14

6.1 Bảng Odds Ratio (OR), 95% CI và p-value 19

A.1 Kết quả đánh giá mô hình trên tập test 27
A.2 Confusion matrix 27
A.3 Bảng Odds Ratio (OR), 95% CI và p-value 27

Tóm tắt (Abstract)

Báo cáo này nghiên cứu bài toán *employee attrition* (nhân viên nghỉ việc) với mục tiêu **(i) dự đoán khả năng nghỉ việc** và **(ii) diễn giải các yếu tố ảnh hưởng**. Dữ liệu gồm 1,470 quan sát; biến mục tiêu là `Attrition` (1 = nghỉ việc, 0 = ở lại).

Phương pháp chính gồm:

- *Logistic Regression* (hồi quy logistic) trong *sklearn pipeline* (pipeline của sklearn) để dự đoán.
- *Logit* (mô hình logit) trong *statsmodels* để suy luận thống kê và báo cáo *Odds Ratio* (tỷ số odds), khoảng tin cậy 95% và p-value.

Kết quả trên tập test (từ `assets/outputs/logistic_metrics.json`): ROC AUC = 0.8031, Accuracy = 0.7517, Precision = 0.3488, Recall = 0.6383, F1 = 0.4511. Về diễn giải, các yếu tố nổi bật gồm: **OverTime_Yes** làm tăng odds nghỉ việc rất mạnh; **EnvironmentSatisfaction** và **JobInvolvement** làm giảm odds nghỉ việc đáng kể.

Chương 1

Giới thiệu

1.1 Bối cảnh và bài toán

Employee attrition (nhân viên nghỉ việc) là hiện tượng nhân sự rời bỏ công ty. Tổ chức thường ưu tiên nhận diện sớm nhóm nhân viên có nguy cơ biến động để triển khai chiến lược giữ chân nhân tài, do chi phí tuyển dụng và đào tạo nhân sự mới thường rất tốn kém.

1.2 Mục tiêu

Báo cáo đặt ra hai mục tiêu:

- **Dự đoán** xác suất nghỉ việc cho từng nhân viên.
- **Diễn giải** yếu tố ảnh hưởng bằng *Odds Ratio* (tỷ số odds) để hỗ trợ quyết định nhân sự.

1.3 Đóng góp (Deliverables)

Các đầu ra chính (artifacts) được lưu trong dự án:

- **Metrics** mô hình: `assets/outputs/logistic_metrics.json`
- **Bảng Odds Ratio**: `assets/outputs/odds_ratio_table.csv`
- **Statsmodels summary**: `assets/outputs/logit_summary.txt`
- **Báo cáo diễn giải OR**: `assets/outputs/odds_ratio_analysis.txt`
- **Hình minh hoạ**: `assets/figures/*.png`

Toàn bộ mã nguồn và pipeline thực nghiệm của báo cáo này được public tại kho GitHub: `https://github.com/mainguyen18/employee-attrition-analysis`.

Chương 2

Dữ liệu

2.1 Nguồn dữ liệu

Dataset sử dụng là `data/WA_Fn-UseC_-HR-Employee-Attrition.csv`. Biến mục tiêu (target) là `Attrition`.

2.2 Đặc tả biến (Feature specification)

Sau khi loại bỏ các biến không mang ý nghĩa dự đoán hoặc không có sự biến thiên (như `EmployeeNumber`, `EmployeeCount`, `Over18`, `StandardHours`, `Department`), các nhóm biến chính đưa vào mô hình gồm:

- **Categorical features** (biến phân loại): `BusinessTravel`, `EducationField`, `Gender`, `JobRole`, `MaritalStatus`, `OverTime`.
- **Numeric features** (biến số): Bao gồm `Age`, `MonthlyIncome`, `YearsAtCompany`, `EnvironmentSatisfaction`, `JobInvolvement`, `DistanceFromHome`, v.v.
- **Biến mục tiêu**: `Attrition` (chuyển đổi từ Yes/No sang 1/0).

Việc đặc tả biến theo nhóm phân loại và biến số liên tục phục vụ trực tiếp cho thiết kế pipeline mô hình: (i) nhóm *categorical* sẽ được mã hoá one-hot (get_dummies) trong bước tiền xử lý, (ii) nhóm *numeric* được chuẩn hoá bằng StandardScaler để phù hợp với Logistic Regression có regularization, và (iii) các cột không có giá trị học thuật bị loại bỏ hoàn toàn.

Mô tả ý nghĩa một số biến nổi bật

- `Age`: Tuổi của nhân viên, đại diện cho thâm niên tuổi đời.
- **Categorical - JobRole**: Vai trò công việc của nhân viên (vd: Sales Executive, Laboratory Technician). Các vai trò khác nhau sẽ có đặc thù áp lực và tỷ lệ nghỉ việc khác nhau.

- **Categorical - OverTime**: Nhân viên có thường xuyên phải làm thêm giờ hay không (Yes/No). Đây là biến số cực kỳ quan trọng phản ánh áp lực công việc.
- `MonthlyIncome`: Thu nhập hàng tháng của nhân viên.
- `EnvironmentSatisfaction`: Đánh giá mức độ hài lòng về môi trường làm việc (từ 1 đến 4). Điểm số này càng thấp, nguy cơ nghỉ việc có thể càng cao.
- `YearsAtCompany`: Tổng số năm nhân viên đã cống hiến tại công ty.
- `DistancefromHome`: Khoảng cách từ nhà đến công ty, ảnh hưởng đến chi phí và thời gian đi lại.
- `Attrition`: Biến mục tiêu nhị phân, bằng 1 (Yes) nếu nhân viên đã nghỉ việc và 0 (No) nếu vẫn đang làm việc tại công ty.

2.3 Tổng quan bộ dữ liệu

Dataset ghi nhận thông tin của 1,470 nhân viên tại công ty, với nhiều biến giải thích bao trùm các khía cạnh: nhân khẩu học, mức độ hài lòng, và chế độ đãi ngộ. Biến mục tiêu là `Attrition`. Tỷ lệ nghỉ việc quan sát được ở mức xấp xỉ 16%, tức là khoảng một phần sáu nhân viên trong mẫu đã chọn rời bỏ công ty.

Nhóm biến *numeric* bao gồm các chỉ báo mức độ hài lòng (như `EnvironmentSatisfaction`, `JobInvolvement`) lẫn các biến phản ánh thời gian và thu nhập (`Age`, `MonthlyIncome`, `YearsAtCompany`), cho phép mô hình hoá cả *chất lượng cảm nhận* và *chế độ tài chính - thâm niên* của nhân viên. Nhóm biến *categorical* (như `OverTime`, `JobRole`) giúp bắt được những yếu tố áp lực ngành nghề và thời gian làm việc vốn đóng vai trò rất lớn trong quyết định nghỉ việc.

2.4 Thống kê mô tả sơ bộ

Kết quả phân tích khám phá (EDA) cho thấy dữ liệu rất sạch, không có thiếu giá trị ở bất kỳ biến nào; do đó không cần áp dụng các bước xử lý missing values (Imputation) phức tạp. Tỷ lệ nghỉ việc 16.12% là một con số phản ánh đúng tính chất của bài toán nhân sự thực tế, nơi chỉ có một nhóm thiểu số nhân viên rời đi, tạo ra bài toán phân loại mất cân bằng (imbalanced classification).

Tóm tắt ở mức tổng quan, bộ dữ liệu có:

- 1,470 quan sát (`n_rows = 1470`).
- Tỷ lệ nhân viên nghỉ việc `Attrition = Yes` ở mức xấp xỉ 16%, phản ánh hiện tượng mất cân bằng lớp.
- Dữ liệu hoàn chỉnh 100%, không có missing values.

2.5 Lưu ý về mất cân bằng lớp

Bài toán dự đoán tỷ lệ nghỉ việc thường có dạng *class imbalance* (mất cân bằng lớp), do số lượng người ở lại luôn áp đảo số lượng người nghỉ việc. Do đó, trong phần mô hình hoá bằng thuật toán Machine Learning, hệ thống sử dụng tham số `class_weight='balanced'` để điều chỉnh tự động trọng số lớp trong Logistic Regression, giúp mô hình nhạy bén hơn trong việc phát hiện những cá nhân sắp nghỉ.

Chương 3

Phương pháp (Methodology)

3.1 Logistic Regression

3.1.1 Mô hình dự đoán xác suất (Bài toán và Công thức)

Định nghĩa bài toán: Mục tiêu là dự đoán xác suất một nhân viên cụ thể sẽ lựa chọn rời bó công ty ($y = 1$, nghỉ việc) dựa trên thông tin hồ sơ của họ (như Tuổi, Mức lương, Mức độ di chuyển, Thời gian làm việc, v.v.).

Công thức thống kê xác suất: Với vector đặc trưng dữ liệu đầu vào $x \in \mathbb{R}^d$ của một nhân viên, mô hình Logistic Regression sử dụng hàm Sigmoid (σ) để tính toán xác suất xảy ra biến cố:

$$p(y = 1 \mid x) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

Cách tính từng phần tử để thay vào công thức trên:

- $\mathbf{p(y = 1 \mid x)}$: Đại lượng đích cần dự đoán, là tỷ lệ phần trăm (0 đến 1) phản ánh nguy cơ nhân viên này sẽ từ chức.
- $\mathbf{x_1, x_2, \ldots, x_d}$: Các biến độc lập quan sát được từ nhân viên. (Ví dụ: x_1 = Số tuổi, x_2 = Mức thu nhập, x_3 = Có làm OT hay không).
- $\boldsymbol{\beta_1, \beta_2, \ldots, \beta_d}$: Các hệ số hồi quy (trọng số) tương ứng. Đây là tham số mà mô hình phải tối ưu. Hệ số dương nghĩa là biến đó làm tăng xát suất bỏ việc; hệ số âm làm giảm xác suất.
- $\boldsymbol{\beta_0}$: Sai số chuẩn (Intercept/Bias), đại diện cho mức rủi ro mặc định.
- **z**: Chỉ số "đòn bẩy"tổng hợp. Để tính z, ta **thế giá trị thực tế** từng yếu tố (x_i) của nhân viên đó, nhân cho mức độ quan trọng (β_i) rồi cộng dồn lại kèm hệ số gốc β_0:

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_d x_d = \beta_0 + \beta^\top x$$

- **e**: Hằng số Euler (≈ 2.718). Cuối cùng, số đo z nhận được sẽ thế thẳng vào hàm $\frac{1}{1+e^{-z}}$ để bẻ cong kết quả trong giới hạn an toàn để thoả mãn tính chất xác suất xác

định (nằm trên đoạn $[0, 1]$).

Bằng thuật toán biến đổi nghịch đảo, phương trình log-odds (logit) của công thức trên trở thành một đường thẳng cấu tạo thuận tiện diễn giải:

$$\log\left(\frac{p}{1-p}\right) = z = \beta_0 + \beta_1 x_1 + \cdots + \beta_d x_d$$

3.1.2 Lựa chọn hàm liên kết logit và cơ sở mô hình

Trong bối cảnh biến mục tiêu nhị phân $y \in \{0, 1\}$, điều quan trọng là mô hình phải đảm bảo $p(y = 1 \mid x)$ luôn nằm trong khoảng $(0, 1)$. Hàm logistic $\sigma(z) = 1/(1 + e^{-z})$ được sử dụng vì:

- $\sigma(z)$ luôn cho giá trị trong $(0, 1)$ cho mọi $z \in \mathbb{R}$, do đó phù hợp để biểu diễn xác suất.
- Hàm logit $\log\left(\frac{p}{1-p}\right)$ tuyến tính theo x, cho phép dùng cùng một khung tuyến tính quen thuộc như trong hồi quy tuyến tính nhưng ở không gian log-odds, giúp việc suy luận và kiểm định trở nên đơn giản và có diễn giải rõ ràng.

Từ góc nhìn xác suất, nếu giả sử các quan sát độc lập và $y_i \sim \text{Bernoulli}(p_i)$ với $p_i = \sigma(\beta_0 + \beta^\top x_i)$, thì log-likelihood của toàn bộ mẫu chính là tổng log xác suất Bernoulli, dẫn tới dạng hàm mục tiêu ở phần tiếp theo.

3.1.3 Lý do lựa chọn Logistic Regression cho bài toán dự đoán nhân sự

Với biến mục tiêu nhị phân và yêu cầu cao về khả năng diễn giải (giải thích được chiều và độ lớn ảnh hưởng của từng yếu tố lên xác suất nghỉ việc), Logistic Regression là lựa chọn tự nhiên: (i) mô hình trực tiếp ước lượng xác suất $p(y = 1 \mid x)$ thay vì chỉ cho ra nhãn cứng, (ii) hệ số β_j có thể được chuyển hoá thành Odds Ratio để diễn giải bằng ngôn ngữ thống kê quen thuộc, và (iii) cấu trúc tuyến tính trong log-odds giúp việc kiểm định giả thuyết, báo cáo p-value và khoảng tin cậy trở nên chuẩn hoá. So với các mô hình phi tuyến phức tạp (như cây quyết định sâu, boosting,...), Logistic Regression mang lại sự cân bằng tốt giữa hiệu năng dự đoán và tính minh bạch, phù hợp với mục tiêu của báo cáo là vừa dự đoán được khả năng rời đi của nhân sự, vừa rút ra được insight định lượng cho đội ngũ quản lý nhân sự (HR).

3.1.4 Hàm mục tiêu và regularization

Mô hình thường tối ưu *Negative Log-Likelihood (NLL)* (âm log-likelihood) và có thể thêm ℓ_2 regularization (phạt ℓ_2):

$$\mathcal{L}(\beta) = -\sum_{i=1}^{n} \Big[y_i \log p_i + (1 - y_i) \log(1 - p_i) \Big] + \lambda \|\beta\|_2^2.$$

Phần đầu của biểu thức trên chính là tổng âm log-likelihood của các biến Bernoulli độc lập, tương ứng với việc tìm β sao cho phân bố xác suất mô hình hoá "giống" dữ liệu quan sát nhất (theo nghĩa Maximum Likelihood). Hạng tử $\lambda\|\beta\|_2^2$ đóng vai trò regularization: phạt các nghiệm có hệ số quá lớn, giúp giảm overfitting và ổn định ước lượng trong trường hợp các biến có tương quan hoặc thang đo khác nhau. Trong triển khai bằng `sklearn`, tham số λ này được mã hoá gián tiếp thông qua tham số nghịch đảo `C` (C lớn tương ứng với regularization yếu, C nhỏ tương ứng với regularization mạnh).

3.1.5 Phân biệt hai vai trò: sklearn Logistic Regression và statsmodels Logit

Trong nghiên cứu này, hai hiện thực khác nhau của mô hình logit được sử dụng song song, phục vụ hai mục đích bổ sung cho nhau:

- **sklearn LogisticRegression** được sử dụng trong *pipeline dự đoán* (prediction pipeline). Mô hình này được tích hợp với *ColumnTransformer* và *StandardScaler* để tạo thành một quy trình huấn luyện–suy luận thống nhất, dễ lưu trữ bằng `joblib` và triển khai lại trên dữ liệu mới. Trọng tâm ở đây là *hiệu năng dự đoán* (predictive performance) thông qua các chỉ số như ROC AUC, Recall và F1.
- **statsmodels Logit** được sử dụng trong *mô-đun suy luận thống kê* (statistical inference). Thay vì ưu tiên tốc độ dự đoán, Statsmodels cung cấp đầy đủ bảng tóm tắt hệ số ước lượng, sai số chuẩn, thống kê kiểm định và *p-value*, cho phép diễn giải từng hệ số β_j dưới dạng *Odds Ratio* cùng khoảng tin cậy 95%. Đây là cơ sở để kết nối mô hình với lập luận thống kê và biện luận học thuật trong luận văn.

Cách tiếp cận hai tầng (prediction bằng sklearn và inference bằng Statsmodels) giúp tách bạch giữa mục tiêu *dự đoán tốt* và mục tiêu *diễn giải sâu*, đồng thời giữ cho kiến trúc hệ thống phân tích được trong sáng và dễ bảo trì.

3.2 Tiền xử lý (Preprocessing)

Thiết kế tiền xử lý theo *sklearn pipeline* (pipeline của sklearn):

- **OneHotEncoder** (mã hoá one-hot) cho biến phân loại.

- **StandardScaler** (chuẩn hoá) cho biến số để ổn định tối ưu khi có regularization.

Việc tách riêng bước tiền xử lý trong một *ColumnTransformer* giúp áp dụng đúng phép biến đổi tương ứng cho từng nhóm biến (one-hot cho categorical, chuẩn hoá cho numeric) một cách có hệ thống và tái lập. Đồng thời, khi ghép *preprocessor* với Logistic Regression vào cùng một *sklearn Pipeline*, toàn bộ quy trình "chuẩn hoá → mã hoá → ước lượng xác suất" được đóng gói thành một đối tượng duy nhất, tránh sai sót do áp dụng thiếu/nhầm bước tiền xử lý khi dự đoán trên dữ liệu mới và thuận tiện cho việc lưu trữ triển khai.

3.3 Thiết kế thí nghiệm

- **Train/Test split** (chia tập train/test) dạng stratified (chia có phân tầng) để giữ tỷ lệ churn tương đồng giữa train và test.
- **Decision threshold** (ngưỡng quyết định) mặc định 0.5 để chuyển xác suất thành nhãn dự đoán; có thể tối ưu theo trade-off Recall/Precision.

Chiến lược chia tập train/test có phân tầng đảm bảo rằng tỷ lệ nghỉ việc trong tập huấn luyện và tập kiểm tra gần như tương đương với tỷ lệ gốc của toàn bộ dữ liệu, giúp đánh giá mô hình khách quan hơn, tránh các trường hợp tập test vô tình quá mất cân bằng. Ngưỡng quyết định ban đầu được đặt ở mức 0.5 như một chuẩn khởi điểm tự nhiên; sau đó, việc phân tích đường cong ROC và confusion matrix cho phép điều chỉnh threshold theo các kịch bản ưu tiên Recall hay Precision khác nhau, phù hợp hơn với yêu cầu chi phí và mục tiêu đánh giá nhân sự.

3.4 Luồng xử lý tổng quát

Quy trình phân tích được triển khai theo một luồng xử lý nhất quán từ dữ liệu thô đến suy luận thống kê:

1. **Nạp dữ liệu và kiểm tra cấu trúc**: đọc file `WA_Fn-UseC_-HR-Employee-Attrition.csv`, kiểm tra số quan sát, số biến, tỷ lệ nghỉ việc và tình trạng thiếu dữ liệu.
2. **Tiền xử lý và tách tập**: áp dụng đặc tả biến để tách (X, y), xây dựng *preprocessor* (one-hot + chuẩn hoá), sau đó chia train/test có phân tầng.
3. **Huấn luyện và đánh giá mô hình**: ghép *preprocessor* với Logistic Regression trong một *sklearn Pipeline*, huấn luyện trên tập train và đánh giá trên tập test bằng các chỉ số như ROC AUC, Accuracy, Recall, Precision, F1 và confusion matrix.
4. **Suy luận thống kê và Odds Ratio**: fit mô hình Logit bằng Statsmodels trên ma trận thiết kế đã dummy hoá, trích xuất hệ số, OR, khoảng tin cậy và p-value để phân tích ý nghĩa thống kê của từng biến.
5. **Tổng hợp kết quả và trực quan hoá**: sinh các bảng kết quả, biểu đồ (ROC, confusion matrix, phân phối theo churn, forest plot OR) và báo cáo văn bản nhằm

kết nối kết quả định lượng với các khuyến nghị nghiệp vụ.

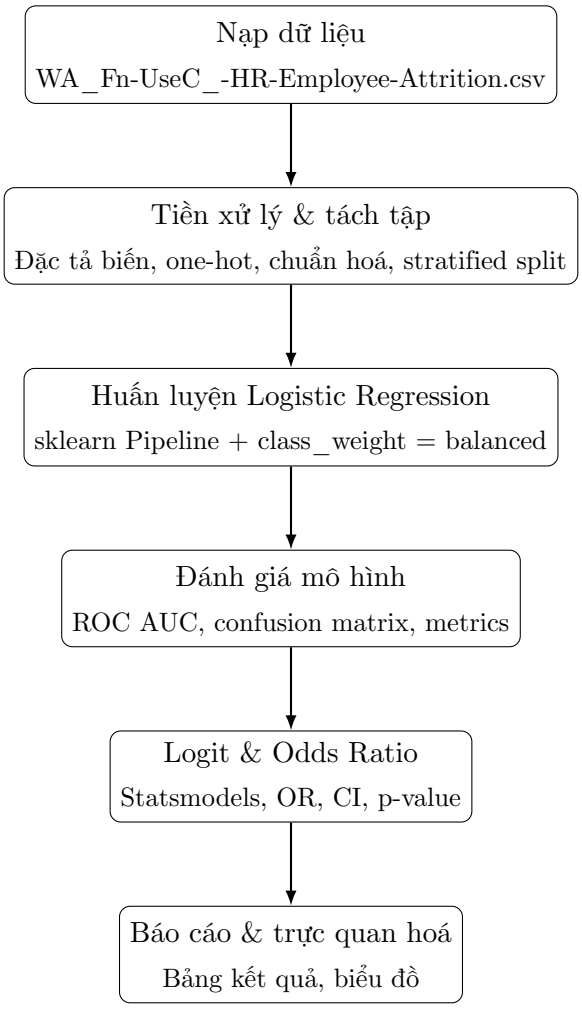

Hình 3.1: Sơ đồ luồng xử lý từ dữ liệu thô đến báo cáo kết quả

Chương 4

Phân tích khám phá (EDA)

4.1 Tỷ lệ nghỉ việc theo nhóm

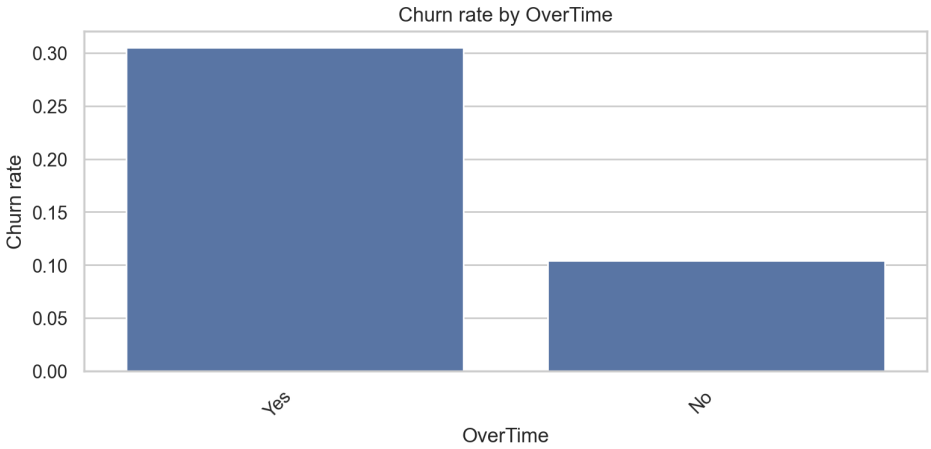

Hình 4.1: Tỷ lệ nghỉ việc theo OverTime

Từ biểu đồ tỷ lệ nghỉ việc theo biến OverTime (Làm thêm giờ), có thể quan sát thấy sự khác biệt vô cùng lớn. Những nhân viên phải làm thêm giờ (Yes) có tỷ lệ nghỉ việc cao hơn hẳn so với những người không phải làm thêm giờ. Điều này cho thấy áp lực công việc và sự mất cân bằng giữa cuộc sống riêng - công việc là động lực chính khiến nhân viên rời bỏ tổ chức. Biến này hứa hẹn sẽ có Odds Ratio rất cao trong mô hình logit.

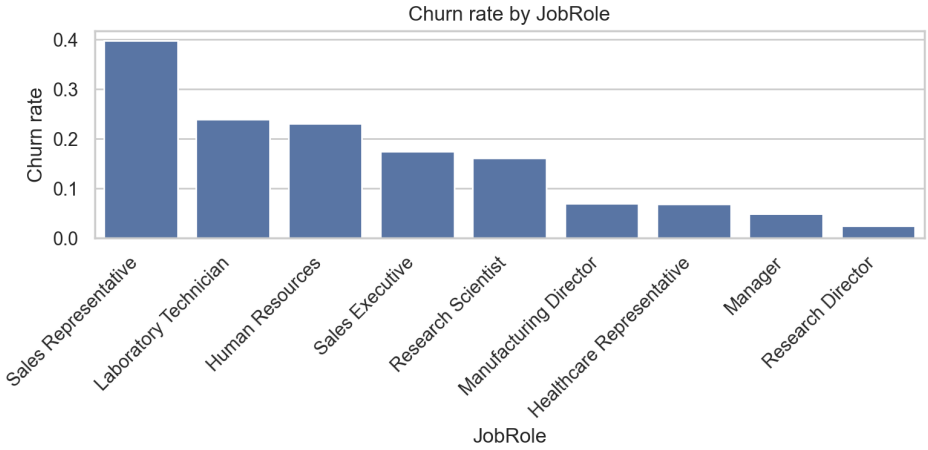

Hình 4.2: Tỷ lệ nghỉ việc theo JobRole

Biểu đồ phân tích theo vai trò công việc (JobRole) cho thấy sự biến động đáng kể giữa các bộ phận. Các vị trí như Sales Representative hoặc Laboratory Technician có xu hướng nghỉ việc cao hơn hẳn so với các vị trí cấp quản lý hoặc nghiên cứu như Manager, Research Director. Đặc trưng của mỗi vị trí mang theo mức độ căng thẳng, tính chất cạnh tranh và cơ hội thăng tiến khác nhau, góp phần giải thích quyết định ở lại hay ra đi của nhân viên.

4.2 Phân phối biến số theo quyết định nghỉ việc

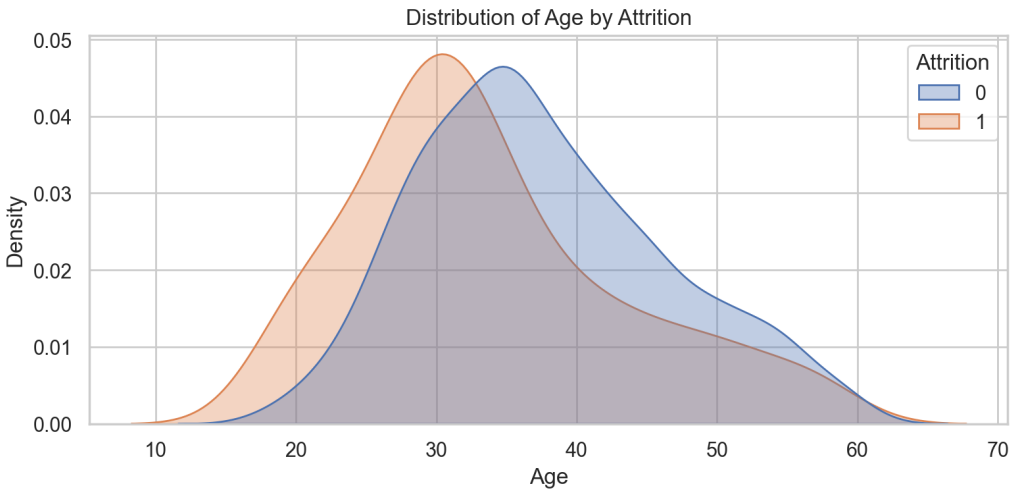

Hình 4.3: Phân phối Age theo trạng thái nghỉ việc

Phân phối độ tuổi (Age) giữa nhóm nghỉ việc và nhóm ở lại cho thấy nhân viên trẻ tuổi (đặc biệt dưới 30) có xu hướng nghỉ việc cao hơn. Đường phân phối của nhóm nghỉ việc (màu đỏ/cam) dịch sang bên trái so với nhóm ở lại. Qua đó, có thể nhận định rằng nhân viên càng trẻ thì độ ổn định càng thấp, họ có thiên hướng tìm kiếm cơ hội hoặc nhảy việc nhiều hơn so với nhân viên lớn tuổi đã an bài sự nghiệp.

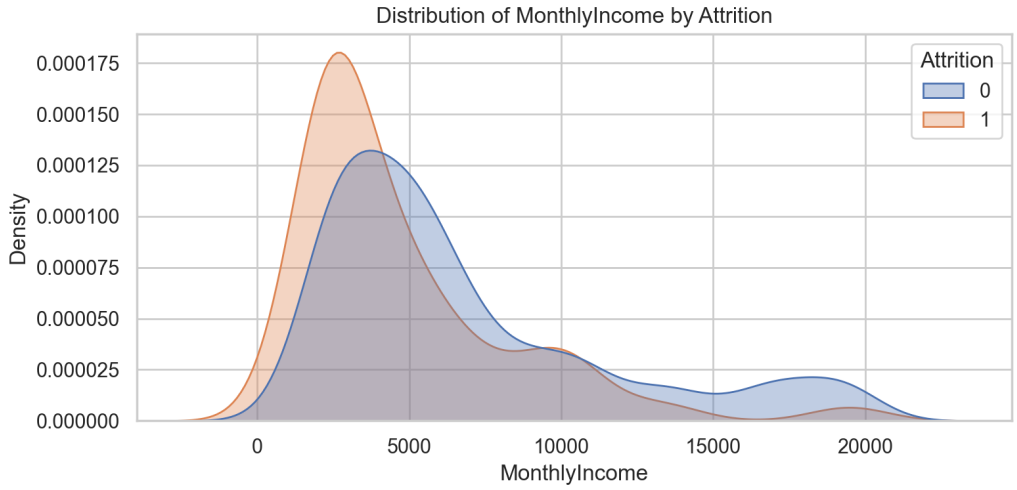

Hình 4.4: Phân phối MonthlyIncome theo trạng thái nghỉ việc

Đối với thu nhập hàng tháng (MonthlyIncome), biểu đồ cho thấy những nhân viên đã nghỉ việc phần lớn tập trung ở vùng thu nhập thấp. Trong khi đó, nhóm ở lại có đường phân phối trải dài hơn về phía các mức lương cao. Chênh lệch này củng cố một thực tế hiển nhiên: lương bổng là một trong những cơ chế giữ chân hiệu quả nhất, và nhóm thu nhập thấp luôn đối mặt với cám dỗ chuyển việc cao nhất nhằm cải thiện tài chính.

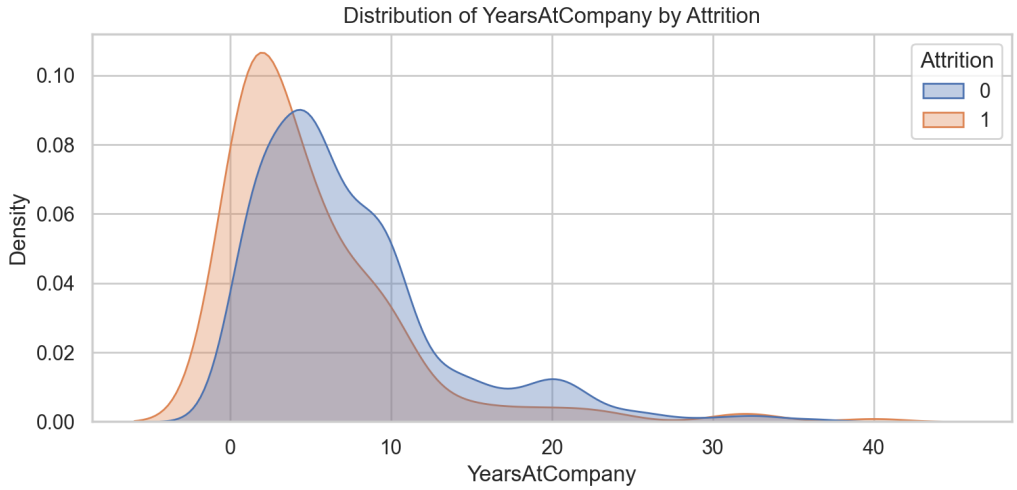

Hình 4.5: Phân phối YearsAtCompany theo trạng thái nghỉ việc

Thâm niên tại công ty (YearsAtCompany) cũng có phân phối khác biệt. Nhân viên có thâm niên ngắn (dưới 5 năm) chiếm phần lớn trong số các ca báo cáo nghỉ việc. Những ai vượt qua được cột mốc vài năm đầu thường có xu hướng gắn bó lâu dài hơn. Điều này gợi ý rằng quá trình hội nhập và đãi ngộ trong những năm đầu là mấu chốt để giảm tỷ lệ hao hụt nhân sự.

Chương 5

Mô hình và đánh giá

5.1 Thiết lập mô hình

Mô hình dự đoán sử dụng *Logistic Regression* (hồi quy logistic) trong *sklearn pipeline* (pipeline của sklearn). Trong bối cảnh mất cân bằng lớp, mô hình dùng `class_weight='balanced'` để giảm thiên lệch về lớp majority.

5.2 Kết quả đánh giá (Metrics)

Bảng 5.1: Kết quả đánh giá mô hình trên tập test

Metric	**Giá trị**
ROC AUC	0.8031
Accuracy	0.7517
Precision	0.3488
Recall	0.6383
F1-score	0.4511

Bảng 5.2: Confusion matrix

	Dự đoán: 0 (Ở lại)	**Dự đoán: 1 (Rời bỏ)**
Thực tế: 0 (Ở lại)	TN = 191	FP = 56
Thực tế: 1 (Rời bỏ)	FN = 17	TP = 30

So với một baseline đơn giản chỉ luôn dự đoán "ở lại" (luôn dự đoán lớp 0), mô hình đạt ROC AUC và Recall cao hơn đáng kể, đồng thời nhận diện được gần 2/3 tổng số nhân viên thực sự sẽ rời đi (Recall 0.64). Điều này mang lại giá trị thực tiễn rất cao trong bối

cảnh phòng Nhân sự (HR) ưu tiên phát hiện sớm nguy cơ chảy máu chất xám để có biện pháp can thiệp.

5.3 Biểu đồ đánh giá

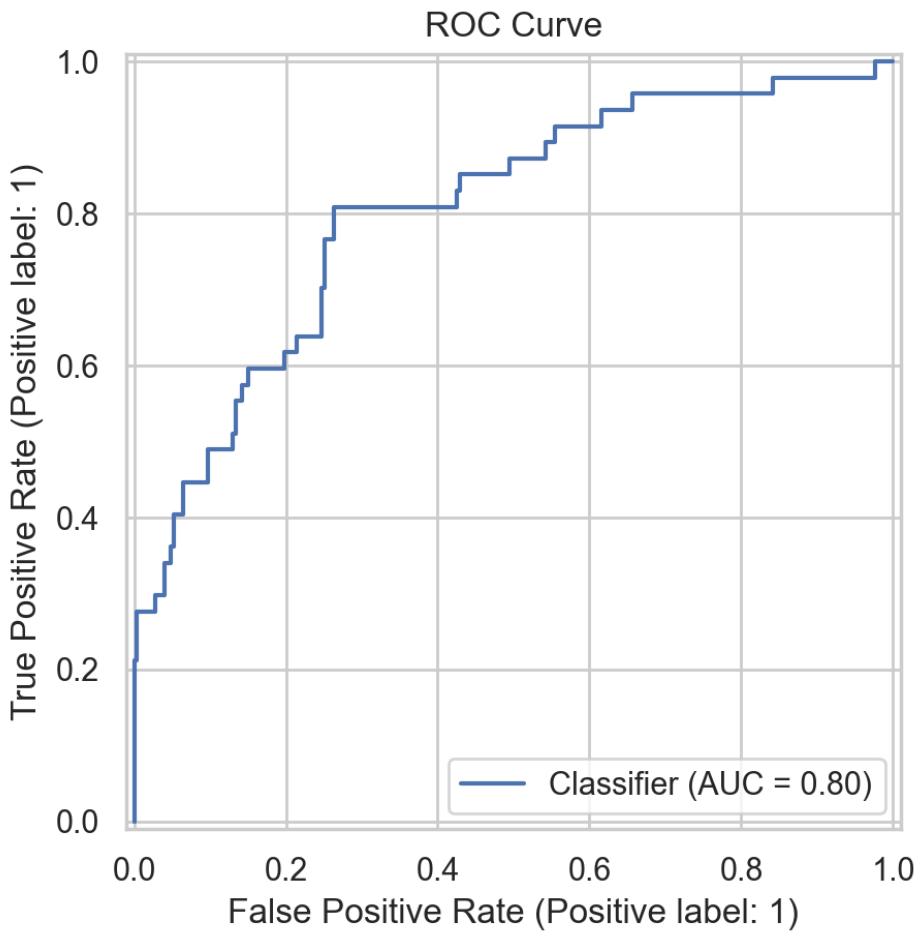

Hình 5.1: ROC curve

Đường cong ROC cho thấy mô hình đạt diện tích dưới đường cong (ROC AUC) xấp xỉ 0.80, cao hơn đáng kể so với đường chéo ngẫu nhiên (AUC = 0.5). Điều này hàm ý rằng, nếu chọn ngẫu nhiên một nhân viên đã nghỉ việc và một nhân viên ở lại, xác suất để mô hình gán điểm rủi ro nghỉ việc cao hơn cho nhân viên thực sự nghỉ việc là khoảng 80%. Khu vực phía trên bên trái của đường cong thể hiện các ngưỡng mà tại đó *True Positive Rate* (TPR) cao trong khi *False Positive Rate* (FPR) vẫn ở mức chấp nhận được, là vùng hoạt động tiềm năng cho các chính sách giữ chân nhân tài của HR.

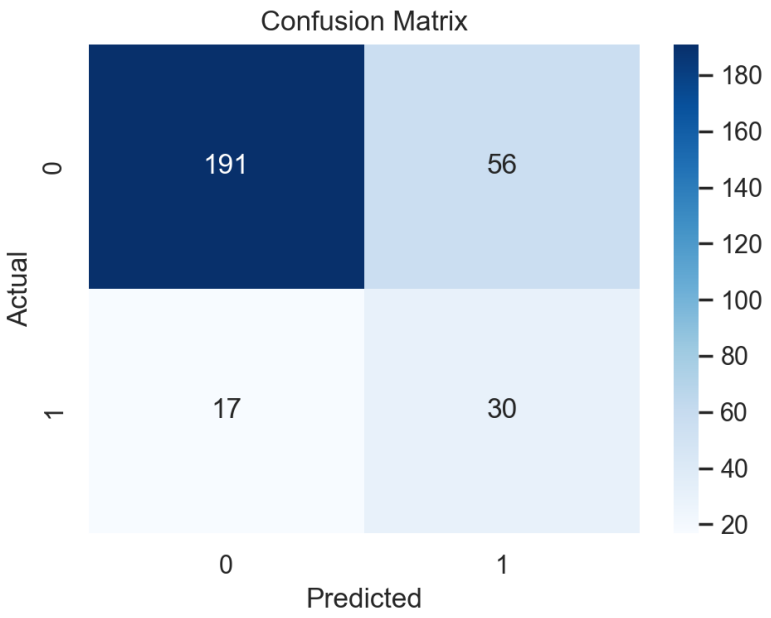

Hình 5.2: Confusion matrix

Confusion matrix minh hoạ chi tiết cách mô hình phân loại trên tập test tại ngưỡng quyết định hiện hành (0.5). Số lượng *True Negative* (TN) cao cho thấy mô hình ít cảnh báo nhầm những người vốn trung thành là sẽ nghỉ việc. Trong khi phần *True Positive* (TP) phản ánh số lượng nhân viên nghỉ việc thực tế được phát hiện đúng. Ngược lại, *False Positive* (FP) tương ứng với các nhân viên bị cảnh báo rủi ro rời đi nhưng thực tế không đổi việc (gây tốn kém nguồn lực chăm sóc dư thừa), còn *False Negative* (FN) là các nhân viên nghỉ việc bị bỏ sót (rủi ro chảy máu chất xám). Với Recall khoảng 0.64, mô hình bắt được 64% các nhân viên sắp rời đi, chấp nhận một tỷ lệ FP nhất định – điều này phù hợp với định hướng nhân sự là thà chăm sóc nhầm còn hơn bỏ sót người tài có nguy cơ ra đi.

5.4 Diễn giải chi tiết về trade-off

Kết hợp giữa các chỉ số tổng hợp (ROC AUC, F1, Recall, Precision) và hai biểu đồ trên cho thấy mô hình đang cấu hình theo hướng ưu tiên *không bỏ sót nhân viên có nguy cơ nghỉ việc*. Với tính chất của quản trị nhân sự, *Recall* (độ bao phủ) cao giúp giảm số ca bỏ sót (giảm FN), dù có thể làm giảm *Precision* (độ chính xác) và tăng cảnh báo nhầm (FP).

Mỗi điểm trên đường cong ROC tương ứng với một *decision threshold* (ngưỡng quyết định) khác nhau để chuyển xác suất dự đoán thành nhãn 0/1. Trong thực tế, việc lựa chọn threshold nên dựa trên chi phí và lợi ích cụ thể của tổ chức:

- Nếu chi phí tuyển dụng và đào tạo nhân tài thay thế (do FN) lớn hơn đáng kể so với chi phí của một buổi trò chuyện hay đãi ngộ bổ sung (FP), HR có thể hạ thấp threshold để tăng Recall.
- Ngược lại, nếu ngân sách tăng lương/thưởng rất hạn chế, có thể nâng threshold để

giảm FP, chỉ dồn nguồn lực giữ chân nhóm nhân sự có xác suất nghỉ việc ở mức báo động đỏ.

Do đó, mô hình Logistic Regression không chỉ cung cấp điểm dự đoán duy nhất, mà còn cho phép xây dựng *đường cong lựa chọn threshold* phù hợp với các kịch bản kinh doanh khác nhau dựa trên cùng một bộ xác suất đầu ra.

Chương 6

Suy luận thống kê: Odds Ratio (OR)

6.1 Từ hệ số β đến Odds Ratio

Trong mô hình logit:

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \sum_{j=1}^{d} \beta_j x_j.$$

Với mỗi biến x_j, *Odds Ratio* (tỷ số odds) được định nghĩa:

$$OR_j = \exp(\beta_j).$$

Diễn giải: nếu tăng x_j thêm 1 đơn vị (giữ các biến khác không đổi), odds nghỉ việc sẽ nhân với OR_j.

6.2 Kiểm định giả thuyết cho từng hệ số

Khi báo cáo p-value cho từng hệ số β_j, ta thực chất đang kiểm định:

$$H_0 : \beta_j = 0 \quad \Leftrightarrow \quad OR_j = 1$$

chống lại giả thuyết đối:

$$H_1 : \beta_j \neq 0 \quad \Leftrightarrow \quad OR_j \neq 1.$$

Với mức ý nghĩa $\alpha = 0.05$, nếu p-value $< \alpha$ thì bác bỏ H_0, kết luận biến x_j có ý nghĩa thống kê (tác động đáng kể lên log-odds nghỉ việc); ngược lại, không đủ bằng chứng để khẳng định biến đó khác 0 trong mô hình hiện tại.

6.3 Baseline (nhóm tham chiếu) cho biến phân loại

Do categorical được dummy hoá theo cơ chế *drop-first* (loại một nhóm làm baseline), các biến:

- `OverTime_Yes` được hiểu **so với baseline OverTime_No**.
- `Gender_Male` được hiểu **so với baseline Gender_Female**.
- Các JobRole (như `JobRole_Sales Representative`) so với **baseline JobRole**.

6.4 Bảng OR và Forest plot

Bảng 6.1: Bảng Odds Ratio (OR), 95% CI và p-value

Feature	**OR**	**95% CI**	**p-value**
OverTime_Yes	7.2785	[4.9777, 10.6429]	1.33×10^{-24}
EnvironmentSatisfaction	0.6476	[0.5506, 0.7618]	1.56×10^{-7}
NumCompaniesWorked	1.2174	[1.1284, 1.3134]	3.81×10^{-7}
JobSatisfaction	0.6614	[0.5638, 0.7759]	3.84×10^{-7}
BusinessTravel_Travel_Frequently	6.7167	[2.9945, 15.0656]	3.82×10^{-6}
JobInvolvement	0.5892	[0.4635, 0.7488]	1.53×10^{-5}
DistanceFromHome	1.0465	[1.0246, 1.0688]	2.44×10^{-5}
YearsSinceLastPromotion	1.1915	[1.0969, 1.2943]	3.31×10^{-5}
JobRole_Sales Representative	7.1923	[2.4411, 21.1910]	3.45×10^{-4}
MaritalStatus_Single	3.1158	[1.5833, 6.1315]	0.0010
YearsInCurrentRole	0.8644	[0.7910, 0.9446]	0.0013
RelationshipSatisfaction	0.7748	[0.6593, 0.9105]	0.0019
JobRole_Laboratory Technician	4.3769	[1.6963, 11.2937]	0.0023
WorkLifeBalance	0.6895	[0.5408, 0.8793]	0.0027
YearsWithCurrManager	0.8763	[0.7991, 0.9610]	0.0050
BusinessTravel_Travel_Rarely	2.7766	[1.3189, 5.8454]	0.0072
TrainingTimesLastYear	0.8295	[0.7190, 0.9570]	0.0104
YearsAtCompany	1.0944	[1.0148, 1.1803]	0.0192
JobRole_Sales Executive	2.7824	[1.1577, 6.6869]	0.0222
Age	0.9695	[0.9441, 0.9956]	0.0222
Gender_Male	1.4830	[1.0328, 2.1295]	0.0328
TotalWorkingYears	0.9409	[0.8885, 0.9964]	0.0371

Feature	**OR**	**95% CI**	**p-value**
JobRole_Human Resources	3.7587	[0.9984, 14.1499]	0.0503
StockOptionLevel	0.8069	[0.5926, 1.0986]	0.1730
DailyRate	0.9997169	[0.9992858, 1.0001483]	0.1983
const	7.4013	[0.3229, 169.6507]	0.2104
MaritalStatus_Married	1.3812	[0.8185, 2.3308]	0.2264
JobRole_Research Director	0.3420	[0.0477, 2.4521]	0.2857
JobRole_Research Scientist	1.6960	[0.6427, 4.4752]	0.2860
EducationField_Medical	0.5117	[0.1162, 2.2529]	0.3756
EducationField_Other	0.5203	[0.1036, 2.6134]	0.4276
EducationField_Life Sciences	0.5638	[0.1280, 2.4821]	0.4485
PercentSalaryHike	0.9783	[0.9059, 1.0564]	0.5755
EducationField_Technical Degree	1.4123	[0.3072, 6.4929]	0.6574
JobRole_Manufacturing Director	1.2463	[0.4387, 3.5405]	0.6794
MonthlyRate	1.0000051	[0.9999806, 1.0000296]	0.6833
PerformanceRating	1.1346	[0.5197, 2.4772]	0.7512
JobLevel	0.9135	[0.4914, 1.6981]	0.7748
HourlyRate	1.0011	[0.9925, 1.0098]	0.8085
EducationField_Marketing	0.8415	[0.1737, 4.0775]	0.8303
JobRole_Manager	1.1686	[0.2495, 5.4729]	0.8433
MonthlyIncome	1.0000111	[0.9998515, 1.0001708]	0.8912
Education	1.0025	[0.8442, 1.1905]	0.9769

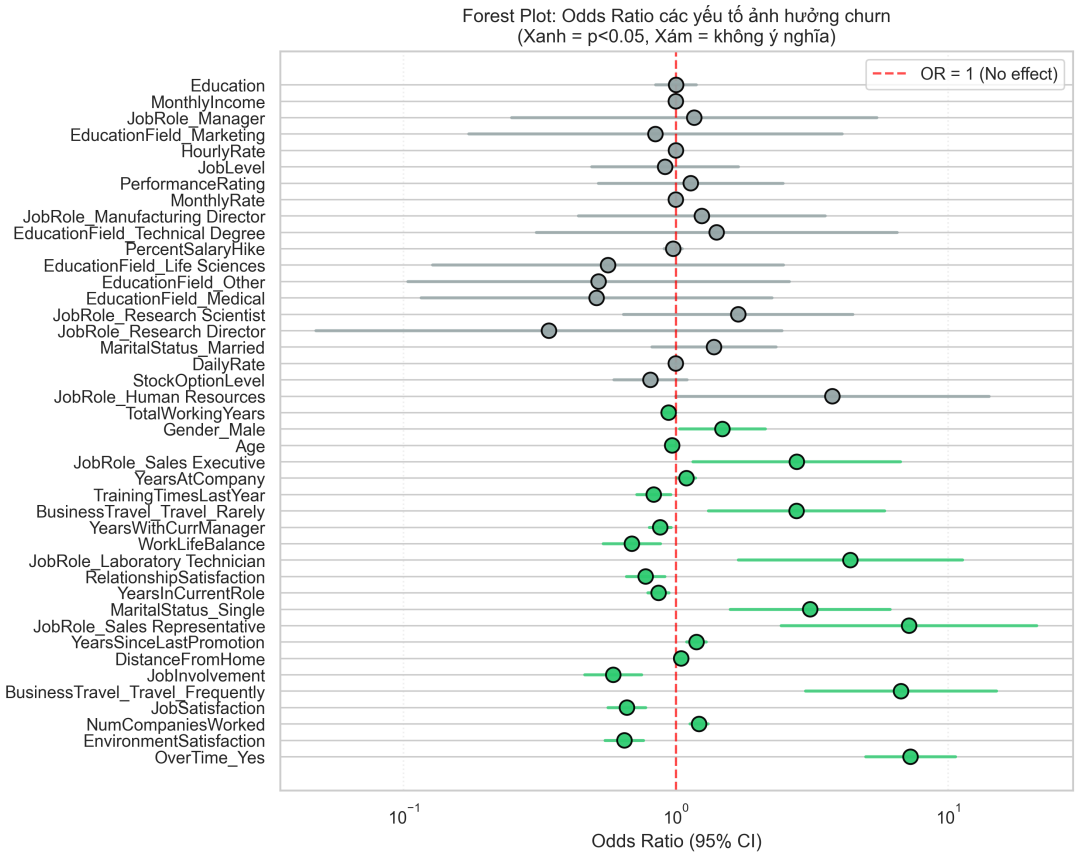

Hình 6.1: Forest plot Odds Ratio

Trong bảng OR, mỗi dòng tương ứng với một biến (hoặc nhóm tham chiếu dummy) trong mô hình logit. Forest plot trực quan hoá cùng một thông tin: trục hoành ở thang log hoặc thang OR, với điểm giữa là OR ước lượng, đoạn thẳng ngang biểu diễn 95% CI và đường dọc tại OR = 1 là ranh giới "không hiệu ứng". Các biến có đoạn CI không cắt qua 1 và nằm xa về một phía thể hiện tác động mạnh và ổn định lên quyết định nghỉ việc.

6.5 Một số điểm diễn giải trọng tâm

- **OverTime_Yes**: OR cực kỳ cao (quanh mức 7.2). Nghĩa là nhân viên phải làm thêm giờ có odds nghỉ việc cao gấp ≈ 7 lần so với người không làm thêm giờ (với các điều kiện khác không đổi).
- **JobRole_Sales Representative**: OR cao (quanh 7.1), cho thấy rủi ro nghỉ việc đặc thù rất lớn ở vị trí nhân viên bán hàng.
- **EnvironmentSatisfaction**: OR ≈ 0.64. Tăng 1 điểm hài lòng về môi trường làm việc làm giảm 36% odds nghỉ việc.
- **JobInvolvement**: OR ≈ 0.58. Sự gắn kết với công việc tăng lên giúp giữ chân nhân viên hiệu quả.

Nhìn tổng thể bảng OR, có thể nhóm các biến thành hai loại chính: (i) *yếu tố rủi ro* với

OR > 1 làm tăng odds nghỉ việc (OverTime, Sales Representative, DistanceFromHome), và (ii) *yếu tố bảo vệ* với OR < 1 làm giảm odds nghỉ việc (EnvironmentSatisfaction, JobInvolvement, RelationshipSatisfaction). Các biến liên tục như `MonthlyIncome` có OR rất gần 1 vì đơn vị tính là 1 USD; trên thực tế, tác động biên của 1000 USD sẽ lớn hơn rất nhiều.

Các yếu tố như OverTime và EnvironmentSatisfaction đều có p-value cực nhỏ, cho thấy ảnh hưởng của chúng lên quyết định nghỉ việc là vô cùng ổn định. Từ góc độ nghiệp vụ (HR), *OverTime* là chỉ báo rủi ro cần được giám sát nghiêm ngặt, trong khi việc nâng cao *EnvironmentSatisfaction* là đòn bẩy chính sách lâu dài.

6.6 Phương trình logit ước lượng

Về mặt lý thuyết, mô hình logit giả định rằng log-odds nghỉ việc là một hàm tuyến tính lập trên ma trận thiết kế đã dummy hoá:

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \sum_{j=1}^{d} \beta_j x_j.$$

Các hệ số $\hat{\beta}_j$ chính là $\ln(OR_j)$. Vì số lượng biến quá lớn, việc trình bày toàn bộ phương trình sẽ gây loãng thông tin. Bảng Odds Ratio phía trên và `assets/outputs/logit_summary.txt` cung cấp đầy đủ bức tranh định lượng để tra cứu hệ số chính xác. Một nhân viên có x_j nhất định sẽ có xác suất rời công ty được tính qua:

$$p = \sigma(\text{logit}) = \frac{1}{1 + e^{-\text{logit}}}.$$

Chương 7

Thảo luận và hạn chế

7.1 Về ý nghĩa thực tiễn của OR với biến liên tục

Một điểm quan trọng khi diễn giải *Odds Ratio* (tỷ số odds) là OR được hiểu theo **mức tăng 1 đơn vị** của biến. Với các biến có đơn vị rất lớn như `MonthlyIncome` hoặc `DailyRate`, OR theo "1 đơn vị" có thể rất gần 1 dù vẫn có ý nghĩa thống kê. Do đó, khi viết báo cáo cho team HR, ta có thể **rescale** (đổi thang đo) theo 1,000 hoặc 5,000 đơn vị (USD) để diễn giải dễ hiểu hơn về sức mạnh thực sự của lương thưởng.

7.2 Ngưỡng quyết định (Decision threshold) và trade-off

Trong đánh giá hiện tại, nhãn dự đoán được suy ra theo ngưỡng 0.5. Tuy nhiên, bài toán attrition là bài toán mất cân bằng lớp; ngưỡng 0.5 hiếm khi tối ưu. Trong triển khai thực tế, bộ phận HR nên chọn ngưỡng theo mục tiêu:

- **Ưu tiên Recall** (giảm bỏ sót nhân sự giỏi sắp nghỉ): giảm threshold $\Rightarrow$ tăng TP nhưng tăng FP.
- **Ưu tiên Precision** (giảm chi phí tăng lương/đãi ngộ nhầm cho người vốn không định đi): tăng threshold $\Rightarrow$ giảm FP nhưng tăng FN.

7.3 Giả định và các hướng kiểm định bổ sung

Logistic Regression/Logit giả định quan hệ tuyến tính giữa biến và log-odds, có thể bị vi phạm nếu có phi tuyến hoặc tương tác biến. Một số hướng mở rộng hợp lý:

- *VIF* (Variance Inflation Factor - hệ số phóng đại phương sai) để kiểm tra đa cộng tuyến.

- Kiểm tra tuyến tính của logit (ví dụ biến bậc hai, spline, hoặc binning cho biến liên tục).

7.4 Ý nghĩa của intercept (hệ số chặn)

Từ `assets/outputs/logit_summary.txt`, $\beta_0 \approx -3.3923$. Khi đó xác suất nền tảng:

$$p_0 = \sigma(\beta_0) = \frac{1}{1+e^{-\beta_0}} \approx \frac{1}{1+e^{3.3923}} \approx 0.0326.$$

Lưu ý: β_0 phản ánh "nhân viên cơ sở" khi các biến bằng 0 (mang tính quy ước toán học); để intercept dễ diễn giải hơn trong nhân sự, thường center/standardize biến liên tục trước khi fit.

7.5 Thảo luận mở rộng và tổng kết hạn chế

Từ các kết quả hiện tại, có thể thấy rằng mô hình Logistic Regression cung cấp bức tranh định lượng rõ ràng về các yếu tố rủi ro và bảo vệ đối với churn, nhưng vẫn tồn tại một số giới hạn cần được nhận diện khi diễn giải:

- **Về biến liên tục và đơn vị đo**: OR của `MonthlyIncome` rất gần 1 trên đơn vị gốc (1 USD). Việc chưa rescale trong mô hình hiện tại là chấp nhận được cho phân tích kỹ thuật, nhưng đưa báo cáo cho HR nên cân nhắc tính OR theo block 1000 USD.
- **Về lựa chọn threshold**: ngưỡng 0.5 giúp chuẩn hoá so sánh mô hình, song chưa gắn trực tiếp với hàm chi phí tuyển dụng lại (FN). Báo cáo nên tiến hành tối ưu threshold dựa trên chi phí thay thế nhân sự thực tế.
- **Về giả định mô hình**: các giả định tuyến tính log-odds và không đa cộng tuyến mới được nêu ở mức khái niệm, chưa được kiểm định bằng VIF hay các phép thử phi tuyến.
- **Về diễn giải intercept**: hệ số chặn hiện tại mang ý nghĩa quy ước toán học. Việc xây dựng một "nhân viên chuẩn hóa" trung bình về Age, Income sẽ ý nghĩa hơn.

Những hạn chế này mở ra các hướng hoàn thiện mô hình trong tương lai: điều chỉnh thang đo cho biến liên tục, tối ưu hoá threshold theo chi phí, kiểm định giả định bằng các công cụ chẩn đoán, và cân nhắc so sánh với các mô hình phi tuyến để kiểm tra độ bền của các kết luận về chiều và độ lớn của hiệu ứng.

Chương 8

Kết luận và khuyến nghị

8.1 Kết luận

Dựa trên kết quả hiện tại (artifacts trong `assets/outputs/`):

- Mô hình Logistic Regression đạt ROC AUC = 0.8031 và Recall = 0.6383 trên tập test.
- Phân tích Odds Ratio cho thấy yếu tố lớn nhất thúc đẩy nhân viên rời bỏ là **OverTime** và vai trò đặc thù như **Sales Representative**. Ngược lại, việc tăng cường **EnvironmentSatisfaction** và **JobInvolvement** làm giảm đáng kể nguy cơ nghỉ việc.

So với mô hình baseline luôn đoán khách "ở lại", mô hình đề xuất cải thiện rõ rệt khả năng phát hiện nhân tài sắp ra đi, cung cấp các luận cứ định lượng chính xác để phòng Nhân Sự hành động sớm.

8.2 Khuyến nghị (Actionable recommendations)

- Cải thiện **EnvironmentSatisfaction** và theo dõi sát sao mức độ hài lòng về môi trường làm việc vì đây là rào chắn hiệu quả chống lại mong muốn nghỉ việc.
- **Tuyệt đối lưu tâm đến OverTime**: Việc bắt buộc nhân viên làm ngoài giờ làm tăng mạnh xác suất nghỉ việc. Cần cân đối lại workload.
- Đánh giá lại cơ chế đãi ngộ và hỗ trợ tinh thần cho các **Sales Representative** vì nhóm này có biến động rất lớn.
- Tối ưu **decision threshold** theo chi phí (expected cost) thay vì cố định 0.5.

8.3 Tái lập (Reproducibility)

Pipeline tạo lại toàn bộ artifacts và hình minh hoạ (tham khảo thêm `report/README.md`):

```
python scripts/run_pipeline.py
```

Phụ lục A

Phụ lục: Bảng kết quả chi tiết

A.1 Kết quả đánh giá mô hình (metrics)

Bảng A.1: Kết quả đánh giá mô hình trên tập test

Metric	**Giá trị**
ROC AUC	0.8031
Accuracy	0.7517
Precision	0.3488
Recall	0.6383
F1-score	0.4511

Bảng A.2: Confusion matrix

	Dự đoán: 0 (Ở lại)	**Dự đoán: 1 (Rời bỏ)**
Thực tế: 0 (Ở lại)	TN = 191	FP = 56
Thực tế: 1 (Rời bỏ)	FN = 17	TP = 30

A.2 Bảng Odds Ratio đầy đủ

Bảng A.3: Bảng Odds Ratio (OR), 95% CI và p-value

Feature	**OR**	**95% CI**	**p-value**
OverTime_Yes	7.2785	[4.9777, 10.6429]	1.33×10^{-24}
EnvironmentSatisfaction	0.6476	[0.5506, 0.7618]	1.56×10^{-7}
NumCompaniesWorked	1.2174	[1.1284, 1.3134]	3.81×10^{-7}

Feature	**OR**	**95% CI**	**p-value**
JobSatisfaction	0.6614	[0.5638, 0.7759]	3.84×10^{-7}
BusinessTravel_Travel_Frequently	6.7167	[2.9945, 15.0656]	3.82×10^{-6}
JobInvolvement	0.5892	[0.4635, 0.7488]	1.53×10^{-5}
DistanceFromHome	1.0465	[1.0246, 1.0688]	2.44×10^{-5}
YearsSinceLastPromotion	1.1915	[1.0969, 1.2943]	3.31×10^{-5}
JobRole_Sales Representative	7.1923	[2.4411, 21.1910]	3.45×10^{-4}
MaritalStatus_Single	3.1158	[1.5833, 6.1315]	0.0010
YearsInCurrentRole	0.8644	[0.7910, 0.9446]	0.0013
RelationshipSatisfaction	0.7748	[0.6593, 0.9105]	0.0019
JobRole_Laboratory Technician	4.3769	[1.6963, 11.2937]	0.0023
WorkLifeBalance	0.6895	[0.5408, 0.8793]	0.0027
YearsWithCurrManager	0.8763	[0.7991, 0.9610]	0.0050
BusinessTravel_Travel_Rarely	2.7766	[1.3189, 5.8454]	0.0072
TrainingTimesLastYear	0.8295	[0.7190, 0.9570]	0.0104
YearsAtCompany	1.0944	[1.0148, 1.1803]	0.0192
JobRole_Sales Executive	2.7824	[1.1577, 6.6869]	0.0222
Age	0.9695	[0.9441, 0.9956]	0.0222
Gender_Male	1.4830	[1.0328, 2.1295]	0.0328
TotalWorkingYears	0.9409	[0.8885, 0.9964]	0.0371
JobRole_Human Resources	3.7587	[0.9984, 14.1499]	0.0503
StockOptionLevel	0.8069	[0.5926, 1.0986]	0.1730
DailyRate	0.9997169	[0.9992858, 1.0001483]	0.1983
const	7.4013	[0.3229, 169.6507]	0.2104
MaritalStatus_Married	1.3812	[0.8185, 2.3308]	0.2264
JobRole_Research Director	0.3420	[0.0477, 2.4521]	0.2857
JobRole_Research Scientist	1.6960	[0.6427, 4.4752]	0.2860
EducationField_Medical	0.5117	[0.1162, 2.2529]	0.3756
EducationField_Other	0.5203	[0.1036, 2.6134]	0.4276
EducationField_Life Sciences	0.5638	[0.1280, 2.4821]	0.4485
PercentSalaryHike	0.9783	[0.9059, 1.0564]	0.5755

Feature	**OR**	**95% CI**	**p-value**
EducationField_Technical Degree	1.4123	[0.3072, 6.4929]	0.6574
JobRole_Manufacturing Director	1.2463	[0.4387, 3.5405]	0.6794
MonthlyRate	1.0000051	[0.9999806, 1.0000296]	0.6833
PerformanceRating	1.1346	[0.5197, 2.4772]	0.7512
JobLevel	0.9135	[0.4914, 1.6981]	0.7748
HourlyRate	1.0011	[0.9925, 1.0098]	0.8085
EducationField_Marketing	0.8415	[0.1737, 4.0775]	0.8303
JobRole_Manager	1.1686	[0.2495, 5.4729]	0.8433
MonthlyIncome	1.0000111	[0.9998515, 1.0001708]	0.8912
Education	1.0025	[0.8442, 1.1905]	0.9769